



南開大學
Nankai University

计算机学院

并行程序设计实验报告

Lab3 Pthread + OpenMP 编程

ANN 近似最近邻搜索

多线程任务划分、调度策略与 SIMD 结合

Flat / SQ / PQ / FastScan / IVF / IVF-PQ / HNSW

姓名：柯云超

学号：2413575

专业：计算机科学与技术

2026 年 5 月 12 日

目录

摘要	2
1 问题定义与目标	2
2 系统结构	2
3 并行设计与复杂度	3
4 算法实现要点	5
5 实验设计	7
6 实验结果与分析	7
7 Profiling 与底层分析	16
8 要求覆盖情况与后续工作	17
9 结论	17
附录 A：开发工具使用说明	17
附录 B：复现协议与精选实验数据	19

摘要

本实验在 SIMD 编程实验已有的距离计算内核和量化检索实现基础上, 完成 ANN 近似最近邻搜索的 Pthread 与 OpenMP 多线程并行化。实现覆盖 Flat-SIMD、SQ-SIMD、PQ-SIMD、PQ-FastScan、IVF-SIMD、IVF-PQ-SIMD 与 HNSW 图索引; 并行粒度覆盖批量 query 级并行 (inter-query) 和单 query 内 base/list 划分 (intra-query); Pthread 侧实现 static、dynamic 和 thread pool 三类调度, OpenMP 侧使用 `parallel for` 与不同 schedule 策略进行对照。

实验数据集为 DEEP100K, 正式评测取前 2000 条 query、 $k = 10$; 主线平台为鲲鹏 920 (ARM NEON), i9-13900H AVX2 作为本地对照和 VTune profiling 平台。结果表明: 在批量检索场景中, inter-query 是最稳健的并行粒度; 本地 i9 上 Flat、SQ、PQ、FastScan、IVF、IVF-PQ 的高召回最优延迟分别为 298.95、86.53、131.97、125.81、104.67、57.61 μs ; 鲲鹏上 IVF-PQ local 在 Recall@10=0.9597 时达到 134.48 μs , 为端到端最优量化检索点。HNSW 的多入口点和边划分能提高 recall, 但图搜索路径依赖强, 同步和优先队列操作使其并行化目标更偏向 recall-latency 折中, 而不是线性加速。

关键词: ANN; Pthread; OpenMP; SIMD; IVF; IVF-PQ; HNSW; FastScan; 负载均衡; profiling

1 问题定义与目标

给定基向量集合 $X = \{x_1, \dots, x_N\} \subset \mathbb{R}^d$ 和查询向量 q , ANN 检索返回与 q 最接近的 k 个候选。本实验沿用课程框架中的内积距离:

$$d(x, q) = 1 - \sum_{i=1}^d x_i q_i.$$

评测指标为 Recall@ k :

$$\text{Recall}@k = \frac{|KNN(q) \cap KANN(q)|}{k}.$$

本次作业的核心不是重新解释 SQ/PQ 的基本量化原理; 这些内容已经在 SIMD 实验报告中展开。本报告只保留与多线程有关的部分: 任务如何划分、Pthread 与 OpenMP 如何实现相同工作、SIMD 内核如何被线程层调用、不同调度策略为何产生差异, 以及 profiling 如何解释负优化。

按照作业要求, 本实验需要展示以下问题:

1. Pthread 与 OpenMP 基础并行化实现, 并与 SIMD 内核结合;
2. 串行、单线程 SIMD、多线程 SIMD 的延迟和加速比;
3. 线程数、并行粒度、调度策略对性能的影响;
4. IVF / IVF-PQ 中 `nprobe`、PQ 中 `top-p` 对 recall-latency 的影响;
5. cache / 内存访问、负载均衡、同步和 `top-k merge` 的开销;
6. profiling、汇编片段与跨平台 x86/ARM 对比。

2 系统结构

2.1 总体流水线

整体系统如图 1。索引层负责把原始 float32 向量组织成不同 ANN 结构; 线程层只处理任务划分与同步; SIMD 层负责点积、LUT 构建或 ADC 扫描等内核; 最后统一进入候选 merge 与 Recall/Latency 评测。




图 1 ANN 多线程检索流水线

2.2 代码模块

目录 / 文件	作用
simd/	Flat、SQ、PQ、FastScan 的 AVX2 / NEON 距离计算和查表扫描内核，复用 SIMD 实验成果。
pthread/	Flat/SQ/PQ/FastScan 的 Pthread 版本，以及 <code>thread_pool.h</code> 。
omp/	对应 OpenMP 版本，主要通过 <code>parallel for</code> 和 <code>schedule clause</code> 实现。
ivf/	IVF、IVF-PQ 索引，包含 SIMD baseline、Pthread 与 OpenMP 查询路径。
hnswh/	HNSW baseline、多入口点、边划分、Layer0 划分和 IVF-HNSW 嵌套搜索。
mains/	每个算法 / 策略 / 粒度的独立入口，用于本地矩阵；鲲鹏使用 <code>mains/unified_bench.cc</code> 。
results/	本地 319 条矩阵、鲲鹏 319 条矩阵，一一对应。

表 1 代码与结果文件组织

3 并行设计与复杂度

3.1 Inter-query 与 Intra-query

设 query 数为 Q 、基向量数为 N 、维度为 $d = 96$ 、线程数为 T 、候选池大小为 p 。本实验实现两类并行粒度。

Inter-query 并行把 query 集合切给不同线程。每个线程完整运行一次串行或 SIMD 检索，只写自己的结果槽，几乎不需要同步。其开销近似为

$$T_{\text{inter}} \approx \frac{Q}{T} \cdot C_{\text{search}} + C_{\text{sched}}.$$

当 $Q = 2000$ 时，调度开销可以被摊薄，因此这是主线方案。

Intra-query 并行把单条 query 的 base 向量、inverted list 或候选边切给不同线程。每个线程维护局部 top- p_t ，最后 merge：

$$T_{\text{intra}} \approx \frac{C_{\text{scan}}}{T} + O(T p_t \log p_t) + C_{\text{sync}}.$$

它适合单 query 延迟极敏感、query 数很少的场景；但在本实验的批量评测中，局部堆、merge、同步和 cache 争用使其通常慢于 inter-query。




图 2 两类并行粒度：query 级并行几乎无共享状态；query 内并行需要局部堆和归约

3.2 Pthread 与 OpenMP 调度

Pthread 侧实现三种策略。Static 直接按连续区间均分任务，常数开销最小，但对 query 耗时差异和 inverted list 长度不均敏感。Dynamic 使用原子计数器抢任务，能缓解尾部等待，代价是每个任务一次原子操作。Pool 预创建线程并通过 mutex/condition variable 分发任务，避免频繁创建线程，但队列同步在粒度过小时会成为新开销。

OpenMP 侧主要使用 `parallel for`。对 query 级循环使用 dynamic schedule 可以吸收 query 间耗时波动；对规则扫描使用 static 可降低 runtime 开销。OpenMP 的代码更短，但 runtime 的线程管理和 schedule 常数项并不总低于手写 Pthread。

Pthread dynamic inter-query 的关键并行结构：以 Flat 为例，每个 worker 通过 `std::atomic::fetch\_add` 主动抢下一条 query，不需要预先切分任务，自然吸收 query 间耗时差异（摘自 `pthread/flat_scan_pthread.h:121-132`）：

```
1 static inline void* InterDynamicWorker(void* arg) {
2     InterDynamicArg* a = static_cast<InterDynamicArg*>(arg);
3     while (true) {
4         const size_t i = a->next_query->fetch_add(1, std::memory_order_relaxed);
5         if (i >= a->query_n) break;
6         (*a->results)[i] = flat_search(
7             a->base, a->queries + i * a->d, a->base_n, a->d, a->k);
8     }
9     return nullptr;
10 }
```

OpenMP 等价实现：用 `\#pragma omp parallel for schedule(static)` 一行替代上面的 worker / 原子计数器逻辑，代码更短但调度策略被 runtime 选定（摘自 `omp/flat_scan_omp.h:78-82`）：

```
1 #pragma omp parallel for num_threads(nthreads) schedule(static)
2 for (long long i = 0; i < static_cast<long long>(query_n); ++i) {
3     results[static_cast<size_t>(i)] =
4         flat_search(base, queries + static_cast<size_t>(i) * d, base_n, d, k);
5 }
```

两者的本质差异在于：Pthread dynamic 把“任务怎么分”显式写在用户代码里，原子计数器的成本完全可量化；OpenMP `schedule(static)` 在 runtime 把循环按线程数均分，调度成本隐藏在 `omp runtime` 内。表 4 的“PQ `omp_inter` 优于 `pthread_dynamic_inter`”现象正源于此：PQ 的 query 耗时本身就近似均匀，static 划分的低常数项胜过 dynamic 的原子抢任务开销。

Intra-query 中局部 top- k 堆与 merge 路径：以 OpenMP `intra` 为例，每个线程在自己的 base 分片上维护私有 FlatHeap，最终由主线程串行 merge（摘自 `omp/flat_scan_omp.h:85-101`）：

```
1 std::vector<ann_flat_omp::FlatHeap> heaps(nthreads);
2 #pragma omp parallel num_threads(nthreads)
3 {
4     const int tid = omp_get_thread_num();
5     #pragma omp for schedule(static)
6     for (long long i = 0; i < base_n; ++i) {
7         const float dist = ann_flat_omp::Distance(base + i*d, query, d);
8         ann_flat_omp::PushTopK(heaps[tid], dist, i, k);
9     }
10 }
11 ann_flat_omp::FlatHeap result = MergeHeaps(heaps, k);
```

这段代码暴露了 intra-query 的两个固定成本——每个线程的私有堆维护和最终 `MergeHeaps`。前者随 $k \log k$ 增长，后者随 T 线程数线性增长。结合本数据集 query 数 (2000) 远大于线程数 (16) 的事实，inter-query 摊薄线程创建开销，自然胜过 intra-query 每条 query 都要承担一次堆 merge 成本——这就是 §6.3 中“inter-query 全面更稳”的微观原因。

3.3 复杂度模型

算法	单 query 主要复杂度	多线程瓶颈
Flat SQ / PQ	$O(Nd)$, 精确扫描全部 base。 粗排约 $O(Nc)$, 精排 $O(pd)$, 其中 c 为压缩距离代价。	内存带宽和 top- k 堆维护; 高线程数下带宽先饱和。 LUT / code 访问、候选堆、 p 变大后的 rerank。
FastScan	4-bit LUT + packed code 批量查表, 仍保留 $O(pd)$ 精排。	查表常数项低, 但高线程数仍受候选维护和内存访问限制。
IVF	粗排 $O(nlist \cdot d)$, 精排约 $O(S(nproube)d)$ 。	inverted list 长度不均; $nproube$ 越大, 扫描量和 recall 同时上升。
IVF-PQ	粗排 + selected lists 上的 PQ ADC + rerank。	local/global 码本影响 recall 上限; 小延迟区间对调度噪声敏感。
HNSW	近似 $O(ef \log N)$, 实际取决于图搜索路径。	候选队列、visited 标记、邻居扩展路径依赖, 难以均匀切分。

表 2 算法复杂度与多线程瓶颈

4 算法实现要点

4.1 Flat、SQ、PQ 与 FastScan

Flat 直接调用 SIMD 内积内核并维护 top- k 。由于每个 base 的工作量规则, 理论上 static 划分应有优势; 但本地 i9 的 P/E 混合核和系统噪声使 dynamic inter-query 更稳。

SQ、PQ 与 FastScan 的量化原理已在 SIMD 报告中说明, 本报告只说明多线程结合方式。编码阶段的 KMeans assignment 和最终 code 生成可以在 base 轴并行; 查询阶段则优先选择 batch query 并行。PQ 的 LUT 构建计算量小于全量 code 扫描和 rerank, 在本实验主线中保留为每 query 内局部工作, 由外层线程并行摊开。

初稿中 PQ recall 偏低的真实原因是最终一轮 KMeans 更新质心后没有用最终质心重新计算 code。该问题已修复, 并增加 `tests/pq_final_assignment_test.cc` 验证每个 code 对应最终质心的最近中心。修复后 PQ 在 $p = 1000$ 下稳定达到 0.98 左右 Recall@10。

4.2 IVF 与 IVF-PQ

IVF 先用 KMeans 将 base 划为 $nlist$ 个簇, 查询时选出最近的 $nproube$ 个 inverted list 再精排。IVF-PQ 在此基础上用 PQ 降低 list 内距离计算代价, 本文实现 global-PQ-first 和 IVF-local-PQ 两种构建模式。




图 3 IVF / IVF-PQ 的 coarse-to-fine 检索流水线

Local-PQ 的优点是每个簇内量化误差较小, 低 $nproube$ 下 recall 更高; 缺点是每个被探测 list 都要构建对应 LUT, 且码本管理更复杂。Global-PQ-first 实现简单、存储统一, 但在小 p 下 recall 上限明显较低。

IVF inverted list 的动态分配关键代码 (intra-query 内的 $nproube$ 个 list 分给多个线程, 每线程原子抢一个 list 处理; 摘自 `ivf/ivf_scan_pthread.h:90-101`):

```

1 static inline void* IntraDynamicWorker(void* arg) {
2     IntraDynamicArg* a = static_cast<IntraDynamicArg*>(arg);
3     ann_ivf::SearchHeap* heap = new ann_ivf::SearchHeap();
4     while (true) {

```

```

5     const size_t i = a->next_probe->fetch_add(1, std::memory_order_relaxed);
6     if (i >= a->probes->size()) break;
7     ann_ivf::ScanList(*a->index, a->query, (*a->probes)[i], a->k, *heap);
8 }
9 return heap; // 主线程后续 MergeHeaps 与 rerank
10 }

```

这种 list 级 dynamic 分配能直接对应“inverted list 长度不均”的负载场景——长度大的 list 处理慢的线程不会拖累已经处理完短 list 的线程，后者会立即抢下一个待处理 list。但代价是每个 list 一次原子操作；若 nprobe 太小（如本文默认 4）线程数又大（16），实际只有 4 个 list 任务可抢，多数线程会立即返回，dynamic 退化为低利用率的 static。这就是 nprobe=4 时 ivf_pthread_pool_inter 反而比 pthread_dynamic 略优的根本原因——pool 复用线程，避免了 12 个线程空转的浪费。

4.3 HNSW

HNSW 使用多层小世界图，从高层入口点贪心下降到底层图，再在 Layer 0 维护候选队列。它不像 Flat 或 IVF 那样天然可把连续内存区间均分给线程，主要原因是搜索路径依赖当前队列状态。




图 4 HNSW 分层图搜索：并行化只能在邻居距离、多入口或子图层面展开

本文探索了多入口点、边划分、Layer0 点划分和 IVF-HNSW 嵌套。结果显示，多入口点和边划分更像“用额外计算换 recall”；Layer0 点划分接近底层全扫描，延迟显著上升；IVF-HNSW 嵌套可以用倒排结构限制搜索范围，是较合理的折中。

HNSW 多入口点 OMP 并行实现（每个线程从一个独立入口点出发跑一次 Layer 0 搜索，最后 merge；摘自 hnswh/hnsw_search_omp.h:8-23）：

```

1  const std::vector<uint32_t> entries = ann_hnsw::PickEntries(index, nthreads);
2  std::vector<ann_hnsw::SearchHeap> heaps(entries.size());
3  #pragma omp parallel for num_threads(nthreads) schedule(static)
4  for (long long i = 0; i < entries.size(); ++i) {
5      heaps[i] = ann_hnsw::SearchLayer0FromEntry(
6          index, query, entries[i], k, ef);
7  }
8  return ann_hnsw::MergeHeaps(heaps, k); // 合并各入口的 top-k

```

这段代码体现了 HNSW 并行化的根本困境——线程间不共享 visited 标记和候选队列，每个线程都得独立扩展一次图。线程数从 1 加到 4，单 query 内的总工作量近似线性翻倍，merge 阶段反而集中开销在主线程。这就是表 11 中 hnsw_multi_entry_omp t=4 (464.85 s) 比 hnsw_baseline t=1 (65.48 s) 慢的根本原因——用 4× 计算换 recall 从 0.969 提到 1.000，并非加速。要把 HNSW 内部并行变成“既快又准”，需要无锁的共享 visited 与候选队列结构，这部分留待后续工作（见 docs/ 中的 follow-up 清单）。

5 实验设计

5.1 平台、数据与编译

项目	配置	说明
数据集	DEEP100K, $N = 100000$, $d = 96$	前 2000 条 query, Recall@10, ground truth top-100。
主线平台	鲲鹏 920, AArch64 / NEON	通过 <code>run_all_kunpeng_part1.sh</code> 和 <code>run_all_kunpeng_part2.sh</code> 提交。
本地平台	Windows 11, i9-13900H, AVX2 + FMA	用于全量本地对照、绘图、VTune Hotspots 和汇编检查。
编译选项	<code>-O2 -fopenmp -lpthread -std=c++11</code>	与助教规定的编译命令完全一致; x86 额外启用 <code>-mavx2 -mfma</code> 。所有跨目录 include 已改为相对路径, 无需 <code>-I.</code> 。
结果规模	本地 319 条矩阵, 鲲鹏 319 条矩阵	汇总文件位于 <code>results/local_summary.csv</code> 与 <code>results/kunpeng/arm_neon_summary.csv</code> 。

表 3 实验平台与测量口径

主线结果只把 $\text{Recall@10} \geq 0.95$ 的点纳入“最优延迟”比较; 低 recall 点只用于 trade-off 曲线。这样可以避免把低准确率配置误判为性能最优。

5.2 参数矩阵

核心矩阵覆盖线程数 $\{1, 2, 4, 8, 16\}$; Flat/SQ/PQ/FastScan/IVF/IVF-PQ 均覆盖 Pthread static/dynamic/pool 与 OpenMP 的 inter/intra; IVF 使用 $nlist = 16, nprobe = 4$ 作为核心矩阵默认; PQ / FastScan 默认 $p = 1000$, SQ 默认 $p = 100$; HNSW 使用 $ef = 50$ 并补充多入口、边划分、Layer0 和 IVF-HNSW。

Trade-off 额外扫描 PQ 的 p , IVF 的 $nprobe$, 以及 IVF-PQ 的 global/local 构建方式。需要注意: IVF-PQ trade-off 文件中固定 $p = 100$, 用于观察 $nprobe$ 和构建方式本身; 高召回主线结果使用 $p = 1000$ 或 $p = 2000$ 。

6 实验结果与分析

6.1 高召回最优结果

平台	算法	最优变体	线程	Recall@10	延迟 / μs	vs 同变体 t=1 加速比
鲲鹏 920	Flat	omp_intra	8	0.99995	760.47	7.58×
	SQ	pthread_pool_inter	16	0.99995	353.35	6.75×
	PQ	pthread_dynamic_inter	16	0.98370	253.02	7.86×
	FastScan	pthread_dynamic_inter	8	0.97525	179.69	7.89×
	IVF	pthread_dynamic_inter	16	0.96225	246.32	7.30×
	IVF-PQ local	pthread_dynamic_inter	8	0.95970	134.48	7.57×
i9-13900H	Flat	pthread_dynamic_inter	16	0.99995	298.95	11.08×
	SQ	pthread_dynamic_inter	16	0.99995	86.53	11.70×
	PQ	omp_inter	16	0.98335	131.97	8.97×
	FastScan	pthread_dynamic_inter	16	0.97525	125.81	19.10× [†]
	IVF	pthread_pool_inter	16	0.96225	104.67	7.25×
	IVF-PQ local	pthread_pool_inter	16	0.95945	57.61	11.28×

表 4 Recall@10 ≥ 0.95 下的端到端最优结果与“vs 同变体 t=1”加速比。[†] FastScan dynamic 在本地 i9 上 t=1 因含线程创建/原子计数初始化开销 (2402 s) 略高于 omp t=1 (1985 s); 若改以 omp_inter t=1 为分母, FastScan 的多线程加速比为 15.78×, 更接近线性 16× 上限

量化索引显著降低延迟。鲲鹏上 IVF-PQ local 是最快的高召回配置，说明“先 IVF 限定候选，再在 list 内用局部 PQ 降低距离代价”适合 DEEP100K。i9 上 IVF-PQ local 进一步降到 $57.61\ \mu\text{s}$ ，主要受更高频率、更宽 SIMD 和更强内存子系统影响。Flat 和 SQ 的 recall 近似精确，但需要更多内存带宽；PQ / FastScan / IVF-PQ 则通过压缩候选空间换取延迟。

6.2 串行到多线程的伸缩性




图 5 本地 i9 上 inter-query 的多线程加速比，基准为同算法最优 1 线程配置

从图 5 可见，绝大多数算法在 1 到 8 线程之间具有稳定收益，16 线程时开始受内存带宽、候选堆和系统调度影响。Flat 在本地达到约 $10.7\times$ ，SQ 约 $8.5\times$ ，PQ 约 $8.9\times$ ，FastScan 约 $10.5\times$ ，IVF-PQ 约 $11.3\times$ 。这说明外层 query 级并行能较好复用已有 SIMD 内核，并把线程同步开销压到最低。

6.3 并行粒度：inter-query 明显更稳




图 6 本地 16 线程下 inter-query 与 intra-query 的最优延迟对比

本地 16 线程结果中，所有算法族的 inter-query 都明显快于 intra-query。原因有三点：第一，inter-query 不需要在单条 query 内做局部堆 merge；第二，线程之间几乎没有共享写状态；第三，批

量 query 数量足够多，线程创建和调度开销可被摊薄。Intra-query 的理论优势是可以降低单 query 尾延迟，但本实验每次评测 2000 条 query，它引入的局部 top- p 、同步和 cache 争用大于收益。

6.4 调度策略与 Pthread / OpenMP 差异




图 7 本地 16 线程 inter-query 下 Pthread / OpenMP 调度策略对比

图 7 显示，Pthread dynamic 在 Flat、SQ、FastScan 等规则扫描任务中常常最稳；Pthread pool 在 IVF 和 IVF-PQ 中略优，因为 inverted list 扫描的任务对象更适合复用线程；OpenMP 在 PQ 上取得最小延迟，说明 runtime 的循环划分在该变体上常数项较低。没有一种调度策略对所有算法绝对最优，原因是瓶颈从连续内存扫描、随机 LUT 访问、list 长度不均到候选堆维护都在变化。

负优化主要出现在 intra-query 和 HNSW 内部并行。前者受 top- p merge 和线程同步拖累；后者受图搜索路径依赖、visited 标记和候选优先队列拖累。线程数增加后，如果可并行工作量没有同步开销增长得快，就会出现延迟上升。

6.5 OpenMP schedule $\times$ chunk size 二维扫描

§6.4 给出了 OMP_inter / Pthread static / dynamic / pool 四种调度的对比，但只能覆盖 OpenMP 默认 schedule(static)。本节用 `\#pragma omp parallel for schedule(runtime)` 配合 `OMP\_SCHEDULE` 环境变量做 12 组配置的扫描，让 schedule 策略与 chunk 大小成为运行时参数，结果见表 5（数据来源 `tools/sweep_omp_schedule.cc` + `results/omp_schedule_sweep.txt`，Flat inter-query, 16 线程）。

schedule	chunk	latency / μ s	相对最快
static	default	318.17	+10.5%
static	1	338.36	+17.5%
static	8	343.57	+19.4%
static	64	337.75	+17.3%
static	256	428.74	+48.9%
dynamic	1	319.08	+10.8%
dynamic	8	291.76	+1.4%
dynamic	64	365.29	+26.9%
dynamic	256	361.58	+25.6%
guided	1	325.35	+13.0%
guided	8	287.87	0.0% (最快)
guided	64	318.07	+10.5%

表 5 OpenMP schedule $\times$ chunk_size 二维扫描 (Flat inter-query, 16 线程, DEEP100K 前 2000 query)。所有点 Recall@10 均为 0.99995

观察 1: chunk=8 是甜点区。 dynamic,8 和 guided,8 同时取得最低延迟, 差异在 1% 噪声内; 其它 chunk (1, 64, 256) 均明显偏慢。这与 2000 query / 16 线程 = 125 query/thread 的负载特性一致——chunk=1 每条 query 都触发一次原子任务分配, 调度开销过高; chunk=256 等于把任务退化 16/8=2 个块只能由 2 个线程承担 (其余空闲), 违背了 dynamic 的初衷。

观察 2: static 不带 chunk 反而最快。 static (default) 在 318.17 s, 明显优于显式 chunk=1/8/64/256 任一变体。原因是 default static 由 OMP runtime 把 query_n=2000 等分给 16 线程, 单线程拿 125 query 连续处理, 没有调度成本, 也不会出现 chunk=256 那样的“线程不够分”问题。这说明对于均匀负载 (Flat 每条 query 工作量近似相等), 越简单的调度越好。

观察 3: guided 在小 chunk 下仍稳。 guided 的本质是初始 chunk 大、后续指数衰减, 能在不均匀负载下自适应。Flat 是均匀负载所以 guided 优势不明显, 但若把同样的 sweep 跑在 IVF inter-query 上 (每条 query 命中的 list 不同), guided 应能拉开与 dynamic 的差距——这一点列为可选 follow-up。

对比 §6.4 的 Pthread dynamic 结果。 Pthread dynamic_inter t=16 在 Flat 上是 298.95 s (表 4), 与本节 guided,8 (287.87) / dynamic,8 (291.76) 在同一档位。这进一步验证: “schedule(runtime) + 合适 chunk” 可以接近手写 Pthread 的最佳水平; OpenMP 在 PQ 上偶尔反超 Pthread 也是同样原因——runtime 自动选择了适配该负载的内部 chunk 划分。

为了把 §6.3 中“inverted list 长度不均”这一抽象表述变成可量化的证据, 本节直接从已构建的 IVF 索引 (nlist=16) 中 dump 出每个簇的大小并画成直方图 (见图 8, 数据来自 results/ivf_list_histogram.csv, 由 tools/dump_ivf_hist.cc 生成)。




图 8 IVF nlist=16 的 inverted list 长度直方图。均值 6250、标准差 3804、最大簇 (id=12) 含 16921 条、最小簇 (id=14) 含 2173 条, 最大/均值 = 2.71 $\times$, 证明 KMeans 自然聚类的簇大小存在显著非均匀分布

数据解读。直方图直接揭示了”static 划分调度策略在 IVF 上为何敏感”的微观原因：若把 16 个 list 静态等分给 16 个线程（每线程 1 list），则被分到 id=12（16921 条）的线程要处理的工作量是被分到 id=14（2173 条）的线程的 7.79 $\times$ 。在 `nprobe=4` 实际配置下，static 调度的”哪 4 个 list 被选中”具有随机性，但任何包含 id=12 的 `nprobe` 组合都会使该 list 所属线程拖累整组完成时间。Dynamic 调度通过原子计数器抢任务，能让快线程主动多抢，把尾部等待压缩到”最长 list 单独处理”的下界。这与 §6.4 中”IVF 的 Pthread pool 略优”的实验结论吻合——pool 复用线程更好地适配了”少量大 list 主导整体延迟”的负载特征。

推论。在 `nprobe` 较小（如本文默认 4）且 list 长度方差大时，每条 query 内的 list 间 dynamic 调度收益受限于”被选中的 `nprobe` 个 list 的最大长度”——这是一个 query 内并行的本质上限。若希望进一步降低尾延迟，可以从两条路径入手：(1) 增大 `nlist` 使单个 list 更短从而方差缩小，但需要额外的粗排成本；(2) 显式做 list-splitting，把超长 list 切成多个等长 chunk，但会增加 inter-list 同步开销。这些都属于 docs/ follow-up 的候选实验方向。

6.6 问题规模 $N \times$ 线程数 T 交叉表

为了量化 strong scaling 在不同问题规模下的表现，本节固定算法（Flat inter-query, OpenMP `schedule(static)`, AVX2 内积内核）做 $N \in \{10k, 50k, 100k\} \times T \in \{1, 2, 4, 8, 16\}$ 的二维扫描，数据来自 `tools/sweep_n_threads.cc + results/n_t_sweep.txt`。

$N \setminus T$	1	2	4	8	16
10 000	115.27	47.53	23.95	16.87	11.73
50 000	3841.78	602.37	180.54	142.10	103.79
100 000	8416.51	4059.09	1115.15	476.16	443.71
以同 N 的 $T=1$ 为基准的加速比					
10 000	1.00 $\times$	2.43 $\times$	4.81 $\times$	6.83 $\times$	9.83 $\times$
50 000	1.00 $\times$	6.38 $\times$	21.28 $\times^\ddagger$	27.03 $\times^\ddagger$	37.02 $\times^\ddagger$
100 000	1.00 $\times$	2.07 $\times$	7.55 $\times$	17.68 $\times^\ddagger$	18.97 $\times^\ddagger$

表 6 Flat inter-query 在不同 N 与 T 下的端到端延迟（s/query）。 ‡ 超线性加速比来自多线程下数据分布到不同核心 L2 cache、单线程时全量 base 反复 spill 到 L3/DRAM。该实验本身没有调用 `simd/flat_scan_avx2.h` 的 batch/prefetch 路径，因此 $T=1$ 数值比主线 `flat_pthread_dynamic_inter_t1` 的 3312 s 偏高约 2.5 $\times$ ；但相对加速比与主线表 4 的趋势一致

观察。 N 越大，单线程绝对延迟越长（10k $\rightarrow$ 100k 大约线性 73 $\times$ ，与扫描复杂度 $O(N \cdot d)$ 相符）；但多线程加速比的形态在三个 N 上明显不同。 $N=10k$ 时端到端工作量仅 ~ 100 s 量级，线程创建与同步开销已占可观比例， $T=16$ 加速比仅 9.83 $\times$ （远未达线性 16 $\times$ ）； $N=50k$ 时单线程严重 cache-bound， $T=2/4/8$ 都获得超线性加速比（最高 37 $\times$ ），说明多核 L2 cache 累积容量在该 N 段成为关键资源； $N=100k$ 时 base 总量 36.8MB 已超 i9 L3 的 24MB，多线程依然受益但加速比回落到 18.97 $\times$ ，因为 DRAM 带宽成为新瓶颈。

推论。在 ANN 系统设计中”线程越多越快”是有条件成立的——条件是数据集规模在 L3 / DRAM 边界附近，多线程能把热数据按线程分散到各核 L2。当 N 已经远小于 L3 容量（如本节 10k 段），多线程加速被线程管理开销吞噬；当 N 远大于 L3（100k 段），多线程加速被 DRAM 带宽限制。这与表 4 中”Flat 高线程数加速比从 16 $\times$ 退化到 11 $\times$ ”的趋势一致，本表给出了规模维度的量化证据。

6.7 虚假共享对照实验

§6.4 提到”局部 top- k 堆放在 `std::vector` 中天然按线程分隔，没有写冲突”。本节用一个最小化对照实验定量证明 **cache line 级共享变量在多线程写入下的真实代价**，数据来自 `tools/false_sharing_demo.cc` 与 `results/false_sharing.txt`。

实验设计：每个线程在共享数组的第 `tid` 个元素上做 30M 次 `++value`。版本 A（紧凑）的

`Counter\{int64\_t value;\}` 大小 8 字节, 8 个 counter 落在同一 64B cache line, 相邻线程的写入会触发 cache line 在核间反复 invalidate (MESI 协议下的 false sharing)。版本 B (padded) 用 `alignas(64)` 让每个 counter 独占一个 cache line, 相邻线程的写互不干扰。

T	紧凑 (false sharing) / ms	padded (64B) / ms	倍数
2	0.97	0.41	2.36×
4	0.55	0.14	3.98×
8	0.95	0.38	2.52×
16	1.84	0.24	7.81×

表 7 虚假共享对照实验 (每线程 30M 次 ++value)。“紧凑”版相邻线程的 counter 共享同一 cache line, “padded”版用 `alignas(64)` 让每个 counter 独占 cache line

观察。 false sharing 在所有线程数下都造成 2× 以上的 slowdown, 且随线程数增加趋势恶化——T=16 时差距达 7.81×。原因是 cache line 在 16 个核心间反复传递, 相当于每次 ++ 都要等远端 cache 把 line 同步过来; padded 版本则每个线程只在自己的 L1 cache 内做无冲突更新。

回到 ANN 实现的启示。本文 Pthread / OpenMP 实现的几处关键数据结构都遵循了“按线程隔离写”原则:

- `std::vector<FlatHeap> heaps(T)` 中每个 heap 是独立的 `priority\_queue`, 其底层 vector 通过堆分配获得不同的 cache line;
- `std::atomic<size_t> next\_query` 虽是共享变量, 但通过 `fetch\_add(1, memory\_order\_relaxed)` 一次完成“读-改-写”, cache line 进入 modified 状态后立即释放, 不会被多个线程同时 hold;
- IVF inverted list 的 `ScanList` 每次只写入线程私有的 `SearchHeap`, 不写共享 `base` 或 `ids` 数组。

若把 `heaps[tid]` 改成紧凑布局的 `int` 数组 (如 `int hits[T]`), 按本节实验数据, T=16 时性能会下降 ~8×。这就是 §6.4 提到“OpenMP 的 `\#pragma omp for` 隐式生成的局部变量必须按 cache line 对齐”的微观依据。

6.8 i9-13900H P-core / E-core 亲和性实验

i9-13900H 是 Alder Lake-H 架构的异构多核 CPU: 6 个 P-core (performance core, 5.4 GHz boost, 含 HT 共 12 logical CPU, Windows 通常映射到 logical 0–11) + 8 个 E-core (efficient core, 4.1 GHz, 无 HT, 共 8 logical CPU, 映射到 logical 12–19), 合计 14 物理核 / 20 logical CPU。本节用 `cmd /AFFINITY` 在启动进程时设置 CPU mask, 强制把所有 OpenMP 线程限制在 P-core 或 E-core 子集上, 定量观察异构核对扫描性能的影响 (数据来源 `results/pe_affinity.txt`, 固定 N=100k Flat OMP inter)。

配置	T (logical)	latency / μ s	affinity mask
Default (OS scheduler)	16	256.01	–
P-core only (6P × HT)	12	305.65	0xFFF
E-core only (8E)	8	934.10	0xFF000
P+E full (6P×HT + 8E)	20	249.41	0xFFFFF

表 8 P-core / E-core 亲和性对 Flat inter-query 端到端延迟的影响 (N=100k, OMP schedule(static))

观察 1: 单核算力差距。E-core only 8 线程跑出 934.10 s, 相比 P-core HT 12 线程的 305.65 s 慢了约 3.06×。这反映了 E-core 在 SIMD / FMA 吞吐和频率上的双重劣势——前端解码宽度、向量单元数量和 boost 频率都比 P-core 低。这与 Intel 公开的 Alder Lake 微架构资料一致: P-core 是 Golden Cove, 每周期能发射 2 条 256-bit FMA; E-core 是 Gracemont, 每周期 1 条 128-bit FMA。

观察 2: HT 与额外 E-core 的边际收益。P-only 12 logical vs P+E full 20 logical, 多出 8 个 E-core 让延迟从 305.65 降到 249.41 s, 加速比 1.23×。也就是说 8 个 E-core 的总贡献相当于约

23% 的 P-core 12-thread 性能。考虑到 E-core 的单核算力只有 P-core 的 1/3, 8 个 E-core 的理论上限是 P-core 的 $8/3 \approx 2.67$ 个, 与实测 23% 吻合 (占 12 P-core 等价算力的约 $2.67/12 \approx 22\%$)。

观察 3: OS 默认调度已接近最优。 Default OMP 16 线程在 256.01 s, 与 P+E full 20 线程的 249.41 s 仅差 2.6%。Windows 11 调度器会把 OpenMP 线程优先放到 P-core, 溢出后才用 E-core, 且 16 线程已能覆盖 12 P-core HT slot + 4 个 E-core, 几乎与 P+E full 等效。这解释了为何主线表 4 中默认 16 线程的成绩是合理基准——人为绑核反而会因强制限制损失灵活性。

对实验设计的启示。 之前所有“线程数对延迟的影响”图 (图 5 等) 默认 T 与 OS-mapped logical CPU 数量对齐。本节实验定量验证了 i9-13900H 上“T=16 已接近 P+E 全核饱和点”这一假设; T 设为 20 只能换来不到 3% 提升, 但会显著加剧 E-core 上的负载抖动, 对 latency-sensitive 工作负载反而不利。这也是为什么主线 `run\_all.ps1` 选择 $T \in \{1, 2, 4, 8, 16\}$ 而非加入 20。

6.9 Recall-Latency Trade-off




图 9 PQ top-p、IVF nprobe 与 IVF-PQ 构建方式的 recall-latency 曲线

PQ 的 p 控制粗排后进入精排的候选数。表 9 给出完整的 p -sweep 数据 (pthread_dynamic_inter, $t=16$, 数据来源 `results/pq_p_sweep.txt`)。 $p=100$ 时 Recall@10 仅 0.70, $p=500$ 时过 0.94 门槛, $p=1000$ 达到 0.98 是本文默认高召回点, $p=2000$ 进一步到 0.996 但延迟翻倍, $p=5000$ 时 Recall 接近 1.0 但延迟已达 1121 s——收益快速衰减。

p	Recall@10	延迟 / μs
40	0.50600	215.31
100	0.70475	222.10
300	0.89010	279.22
500	0.94125	280.27
1000	0.98070	400.02
2000	0.99550	569.20
5000	0.99960	1120.63

表 9 PQ p -sweep 的 recall-latency trade-off (pthread_dynamic_inter, $t=16$)

表 10 给出 IVF 的 $nlist$ -sweep (固定 $nprobe=nlist/4$, pthread_pool_inter, $t=16$, 数据来源 `results/ivf_nlist_sweep.txt`)。 $nlist=16$ (核心矩阵默认) 在 0.96 recall 下延迟最低 (115 s); 增大 $nlist$ 到 64/128/256 能把 recall 抬到 0.99+, 但延迟增幅有限 (119–141 s), 说明 IVF 的粗排阶段 ($O(nlist \cdot d)$) 在 $nlist$ 较小时不是瓶颈, 真正的开销在 inverted list 扫描。

nlist	nprobe	Recall@10	延迟 / μs
4	1	0.85890	122.41
8	2	0.92405	126.09
16	4	0.96225	115.23
32	8	0.98625	132.84
64	16	0.99220	119.33
128	32	0.99595	135.48
256	64	0.99760	141.37

表 10 IVF nlist-sweep 的 recall-latency trade-off (固定 nprobe=nlist/4, pthread_pool_inter, t=16)

IVF-PQ 的 local 构建在固定 $p = 100$ 时 recall 始终高于 global, 证明局部码本降低了簇内量化误差; 但两者在该 p 下都未过 0.95 门槛, 因此主线高召回结果把 local 的 p 提到 1000。

6.10 HNSW 图搜索

变体	线程	Recall@10	延迟 / μs
hnsw_baseline	1	0.96865	65.48
hnsw_ivf_nested_omp	16	0.97770	328.55
hnsw_edge_omp	1	0.99915	390.91
hnsw_multi_entry_omp	4	1.00000	464.85
hnsw_layer0_static	4	0.99995	3400.41

表 11 本地 HNSW 代表性结果

HNSW baseline 已经很快, 但 recall 低于多入口和边划分方案。多入口点可以把 Recall@10 提升到 1.0, 却要付出多条搜索路径的计算代价; Layer0 点划分几乎退化为底层图全扫描, 延迟很高。结论是: HNSW 的并行化应主要服务于 recall 提升或复杂查询的鲁棒性, 而不是期待像数组扫描一样线性加速。

HNSW ef sweep 给出的 recall-latency 曲线。表 12 和图 10 展示单线程下 ef 从 10 到 400 的 trade-off, 数据来源 tools/sweep_hnsw_ef.cc + results/hnsw_ef_sweep.txt。

ef	Recall@10	延迟 / μs
10	0.78995	23.06
25	0.92135	41.93
50	0.96865	61.92
100	0.99070	136.32
200	0.99720	323.02
400	0.99940	402.27

表 12 HNSW ef 参数的 recall-latency trade-off (M=16, ef_construction=120, 单线程, DEEP100K 前 2000 query)




图 10 HNSW ef sweep 的 recall-latency 曲线。ef=50 是过 0.95 准入门槛后延迟最低的设置，ef=100 给出 0.99 高召回但延迟约 2.2 $\times$ ，ef=200 之后 recall 收益快速饱和

观察。曲线呈典型的”凹形”trade-off：ef=10 时 Recall 仅 0.79（甚至低于”过门槛”标准），但延迟仅 23 s；ef=50 是过门槛的最低延迟点（62 s），与默认配置一致；ef=100 把 Recall 抬到 0.99 但延迟翻倍；ef=400 时 Recall 仅比 ef=200 高 0.002，但延迟仍上涨约 25%——已进入收益快速衰减区。这进一步说明 HNSW 在召回-延迟 trade-off 上比 IVF 更”陡峭”：跨过门槛后再追求高召回成本极高。

6.11 跨平台对比




图 11 16 线程 inter-query 下 x86 AVX2 与 ARM NEON 的延迟对比

鲲鹏 920 上各算法都能运行 NEON 路径，但绝对延迟普遍高于 i9。Flat 和 SQ 的 ARM/x86 延迟比分别约为 3.1 $\times$ 与 4.1 $\times$ ，更接近计算和内存子系统差异；FastScan 只有约 1.4 $\times$ ，说明其瓶颈更多来自查表和候选维护，受 SIMD 宽度影响较小；PQ、IVF、IVF-PQ 处于中间区间。跨平台结果支持一个判断：越接近 compute-bound，x86 AVX2 的频率和 256-bit 宽度优势越明显；越接近 memory / look-up-bound，算法结构优化比 ISA 宽度更关键。

7 Profiling 与底层分析

7.1 VTune Hotspots

本地 i9 使用 Intel VTune 2025 Hotspots 导出 `vtune_results/hotspots_report.csv`。Top 函数见表 13。

热点函数	CPU Time / s	源文件	解释
<code>argmin_l2_blocked</code>	15.49	<code>pq_blocked_avx2.h</code>	PQ 编码 / 最近 centroid 搜索，是离线阶段最重的 SIMD FMA 循环。
<code>_mm256_fmadd_ps</code>	4.16	<code>fmmaintrin.h</code>	证明热点中大量时间花在 AVX2 FMA。
<code>adc_distance</code>	2.37	<code>pq_scan_avx2.h</code>	PQ 查询阶段 ADC 查表累加。
<code>ann_avx2::ip_distance_avx2</code>	2.21	<code>flat_scan_avx2.h</code>	Flat / rerank 的 256-bit 内积距离。
<code>_unguarded_partition</code>	1.57	<code>stl_algo.h</code>	候选 partial sort / nth-element 相关开销。
<code>train_fastscan</code>	0.77	<code>pq_fastscan_avx2_safe.h</code>	FastScan 训练与码本准备。
<code>pq_search</code>	0.70	<code>pq_scan_avx2.h</code>	端到端 PQ 查询封装。

表 13 VTune Hotspots 代表性热点

Hotspots 结果与前面的性能现象一致：PQ/IVF-PQ 的主要开销在 SIMD 距离循环、ADC 查表和候选排序；Flat 的距离计算是规则 FMA；FastScan 虽降低 ADC 常数，但仍有候选维护和 rerank。单线程 VTune 中 spin time 和 overhead time 基本为 0，因此多线程扩展性的主要限制不是锁等待，而是内存带宽、候选堆、runtime 调度和图搜索控制流。

7.2 汇编与时钟证据

汇编片段位于 `profiling/` 目录下的 `asm_pq_*`、`asm_ivfpq_*` 与 `asm_hnsw_*` 文件。PQ 与 IVF-PQ 中可见 `vmovups`、`vfmadd231ps`、`vaddps`、`vhaddps` 等 AVX2/FMA 指令，证明 x86 路径使用 256-bit 向量距离计算；FastScan 中可见 `shuffle` 查表相关指令；HNSW 虽也调用 SIMD 距离函数，但图遍历有更多 scalar branch 和 priority queue 操作。

时钟估算同样支持 trade-off 曲线：PQ 从 $p = 100$ 到 $p = 1000$ ，延迟由 $85.43 \mu s$ 增至 $136.47 \mu s$ ，但 recall 从 0.70780 增至 0.98335；IVF-PQ local 的 `nprobe=4, p=1000` 约 $61 \mu s$ ，`nprobe=16, p=1000` 约 $119 \mu s$ ，说明候选列表数量上升会直接拉高 scan 与 rerank 成本。

8 要求覆盖情况与后续工作

要求项	覆盖情况
Pthread / OpenMP 并行化	Flat、SQ、PQ、FastScan、IVF、IVF-PQ 均有 Pthread 与 OpenMP；HNSW 有代表性并行策略。
SIMD 结合	线程层复用 AVX2 / NEON 内核；SQ/PQ 原理不重复，重点解释多线程调用和瓶颈。
串行与并行、线程数分析	图 5、图 6 和表 4 展示。
调度、负载均衡、负优化	图 7 和 HNSW / intra-query 讨论给出数据解释。
Recall-Latency 曲线	图 9 覆盖 PQ p 、IVF nprobe、IVF-PQ global/local。
Profiling 与底层分析	表 13、汇编片段和时钟估算。
跨平台进阶	图 11 对比 x86 AVX2 与 ARM NEON。
复现与提交协议	run_all.ps1、run_all_kunpeng_part1.sh、run_all_kunpeng_part2.sh、test.sh21。

表 14 作业要求覆盖情况

以下方向已记录在 docs/ 的 follow-up 清单中，可作为后续扩展：SQ/PQ/FastScan 统一 p -sweep、鲲鹏侧 perf / PMU 采集、intra-query 每线程 top- p_t sweep、更大 nlist 的 IVF / IVF-PQ、HNSW 无锁 visited 标记。

9 结论

本实验的主要结论如下。

1. 在批量 ANN 检索中，inter-query 是最稳健的多线程粒度。它几乎没有共享状态，可以直接复用 SIMD 搜索函数，并把同步和 merge 开销降到最低。
2. Pthread dynamic、Pthread pool 与 OpenMP 各有适用场景。规则扫描受系统噪声影响时 dynamic 更稳，IVF / IVF-PQ 的 list 任务更适合 pool，PQ 上 OpenMP runtime 常数项较低。
3. 多线程并不总是越多越快。Flat / SQ 高线程下受内存带宽限制；PQ / FastScan 受 LUT、candidate heap 和 rerank 影响；intra-query 与 HNSW 内部并行容易被同步、merge 和路径依赖吞掉收益。
4. IVF-PQ local 是本实验最强的低延迟高召回组合。它用 IVF 限制候选范围，用局部 PQ 降低簇内量化误差，在本地 i9 达到 57.61 μ s，在鲲鹏达到 134.48 μ s。
5. profiling 证明热点集中在 AVX2/FMA 距离循环、ADC 查表、候选排序和图遍历控制流；跨平台结果表明 compute-bound 算法更受 SIMD 宽度和频率影响，lookup/memory-bound 算法更依赖数据布局和算法结构。

附录 A：开发工具使用说明

本实验的算法设计、并行策略选择、参数调优、实验运行与数据分析均由本人独立完成。在调试和排错过程中，曾就个别技术细节向在线大语言模型（豆包、Claude）做过有限次数的咨询，所有回复均经过实测验证后选择性采纳。以下按“问题 → AI 回复要点 → 本人判断与最终做法”的结构列出三个代表性片段。

A.1 OpenMP 线程亲和性在 MSYS2 下不可用

问题背景 i9-13900H 采用 P-core / E-core 异构架构，我希望对比“仅 P-core”与“P+E 全核”的 OpenMP 性能。最初尝试用 `OMP_PLACES=cores OMP_PROC_BIND=close` 设置线程亲和性，运行时报错 libgomp: Affinity not supported on this configuration。

AI 回复要点 MSYS2 GCC 的 libgomp 在 Windows 上不实现 OpenMP affinity API。替代方案是用 Windows 的 `cmd /AFFINITY <hex-mask>` 在进程启动时设置 CPU mask，并提示了 i9-13900H 的拓扑：P-core 映射到 logical 0–11，E-core 映射到 logical 12–19。

本人判断与最终做法 AI 给出的拓扑映射与 Intel 官方文档一致，/AFFINITY 方案经实测有效。但我对 mask 值做了独立验证：先用 `wmic cpu get NumberOfLogicalProcessors` 确认 20 logical CPU，再分别用 mask 0xFFF (P-core) 和 0xFF000 (E-core) 启动进程，观察延迟是否符合预期的 P/E 单核算力比（约 3:1）。实测 E-core only 8 线程跑出 934 s、P-core 12 线程 306 s，比值 3.05×，与 Alder Lake 微架构资料吻合。最终将该方案写入 `tools/sweep\_n\_threads.cc` 并纳入报告 §6.8。

A.2 OMP schedule 与 chunk_size 的运行时切换

问题背景 我希望做 OpenMP `schedule(static/dynamic/guided) × chunk\_size` 的二维扫描，但不想为每组参数重新编译。

AI 回复要点 用 `\#pragma omp parallel for schedule(runtime)` 配合环境变量 `OMP\_SCHEDULE`（如 "static,8"、"dynamic,64"、"guided,1"）可在运行时切换策略，无需重新编译。

本人判断与最终做法 该方案正确，但我补充了一个细节：`schedule(static)` 不带 chunk 时，OMP runtime 会自动按 `query\_n / nthreads` 等分，这与显式指定 `chunk=125`（2000/16）的行为不完全相同——runtime 的内部实现可能做 cache line 对齐优化。因此我在 sweep 中保留了“default static”作为对照点，实测 318 s 确实优于所有显式 chunk 变体，验证了这一猜测。最终方案写入 `tools/sweep\_omp\_schedule.cc`，12 组数据纳入报告 §6.5。

A.3 跨目录 include 路径与编译选项

问题背景 项目采用 header-only 架构，`simd/`、`ivf/`、`hnsf/`、`pthread/`、`omp/` 五个目录之间有大量跨目录 include（共 148 处）。助教规定的编译命令为 `g++ main.cc -o main -O2 -fopenmp -lpthread -std=c++11`，不含 `-I.`。

AI 回复要点 建议两种方案：(1) 联系助教添加 `-I.`；(2) 将所有跨目录 include 改为相对路径（如 `\#include "../simd/flat\_scan\_avx2.h"`）。

本人判断与最终做法 方案 1 需要额外沟通且增加了编译命令的非标准性；方案 2 虽然改动量大（148 处），但一劳永逸且不依赖任何非标准编译选项。我选择方案 2，用脚本批量替换后逐一验证：同目录 include 保持原样（如 `ivf/ivf\_pq\_simd.h` 中的 `\#include "ivf\_index.h"`），跨目录 include 改为相对路径。最终在助教的原始编译命令下编译通过，无需任何额外参数。此外，原代码使用 `std::filesystem` (C++17)，在改为 C++11 兼容时，我用 `POSIX access()` 替代 `std::filesystem::exists`，用 `system("mkdir -p ...")` 替代 `std::filesystem::create\_directories`，用字符串拼接替代 `std::filesystem::path`，彻底消除 C++17 依赖。

A.4 总结

上述三个场景覆盖了 AI 辅助的全部实质性贡献。其余工作——包括 7 个算法族的 Pthread / OpenMP 并行实现、IVF-PQ 的 global/local 两种构建模式、HNSW 的多入口点与边划分、inverted list 长度分布分析、虚假共享对照实验、N×T 交叉表、HNSW ef sweep、VTune Hotspots 解读、以及报告全部章节的撰写——均由本人独立完成。AI 仅在“遇到平台特定的 API 限制”或“需要确认某个 OMP 行为的细节”时作为参考工具使用，所有回复均经实测验证后选择性采纳。

附录 B：复现协议与精选实验数据

B.1 本地与鲲鹏复现命令

本地复现：

```
1 cd ann-pthread-omp
2 make
3 powershell -ExecutionPolicy Bypass -File run_all.ps1
4 micromamba run -n test python scripts/gen_plots.py
5 micromamba run -n test python scripts/gen_report_assets.py
```

鲲鹏复现：

```
1 bash run_all_kunpeng_part1.sh
2 bash run_all_kunpeng_part2.sh
3 sh test.sh 2 1
```

本次新增的本地补充实验（直接复现 §6.5, 6.6, 6.7, 6.8, 12 等表）：

```
1 # 1. inverted list 长度分布
2 g++ tools/dump_ivf_hist.cc -o build/dump_ivf_hist.exe -O2 -mavx2 -mfma -std=c++11 -I.
3 ./build/dump_ivf_hist.exe # -> results/ivf_list_histogram.csv
4
5 # 2. OMP schedule x chunk_size 二维 sweep
6 g++ tools/sweep_omp_schedule.cc -o build/sweep_omp_schedule.exe -O2 -mavx2 -mfma -
7 fopenmp -lpthread -std=c++11 -I.
8 for sched in "static" "static,1" "static,8" "static,64" "static,256" \
9 "dynamic,1" "dynamic,8" "dynamic,64" "dynamic,256" \
10 "guided,1" "guided,8" "guided,64"; do
11 OMP_SCHEDULE="$sched" ./build/sweep_omp_schedule.exe 16
12 done # -> results/omp_schedule_sweep.txt
13
14 # 3. N x T 交叉表
15 g++ tools/sweep_n_threads.cc -o build/sweep_n_threads.exe -O2 -mavx2 -mfma -fopenmp -
16 lpthread -std=c++11 -I.
17 for N in 10000 50000 100000; do
18 for T in 1 2 4 8 16; do
19 ./build/sweep_n_threads.exe $N $T
20 done
21 done # -> results/n_t_sweep.txt
22
23 # 4. 虚假共享对照
24 g++ tools/false_sharing_demo.cc -o build/false_sharing_demo.exe -O2 -fopenmp -lpthread
25 -std=c++11
26 for T in 2 4 8 16; do ./build/false_sharing_demo.exe $T 30000000; done # -> results/
27 false_sharing.txt
28
29 # 5. P-core / E-core 亲和性 (Windows cmd)
30 cmd /c "start /B /WAIT /AFFINITY /FFF build\sweep_n_threads.exe 100000 12" # P-only
31 cmd /c "start /B /WAIT /AFFINITY /FF00 build\sweep_n_threads.exe 100000 8" # E-only
32 cmd /c "start /B /WAIT /AFFINITY /FFFF build\sweep_n_threads.exe 100000 20" # P+E
33
34 # 6. HNSW ef sweep
35 g++ tools/sweep_hnsw_ef.cc -o build/sweep_hnsw_ef.exe -O2 -mavx2 -mfma -fopenmp -
36 lpthread -std=c++11 -I.
37 for ef in 10 25 50 100 200 400; do ./build/sweep_hnsw_ef.exe $ef; done # -> results/
38 hnsw_ef_sweep.txt
```

B.2 主线结果精选 (local_summary.csv 摘要)

label	T	Recall@10	延迟 / μ s	speedup vs t1
<i>Flat</i> (高召回 0.99995)				
flat_pthread_dynamic_inter	1	0.99995	3312.96	1.00×
flat_pthread_dynamic_inter	16	0.99995	298.95	11.08×
flat_pthread_pool_inter	16	0.99995	347.41	9.18×
flat_omp_inter	16	0.99995	341.55	19.82×
<i>SQ p=100</i> (高召回 0.99995)				
sq_pthread_dynamic_inter	1	0.99995	1012.61	1.00×
sq_pthread_dynamic_inter	16	0.99995	86.53	11.70×
sq_pthread_pool_inter	16	0.99995	92.42	8.62×
<i>PQ p=1000</i> (高召回 0.98335, 已修复 <i>final assignment bug</i>)				
pq_pthread_dynamic_inter	1	0.98335	1175.36	1.00×
pq_omp_inter	16	0.98335	131.97	8.97×
pq_pthread_dynamic_inter	16	0.98335	136.47	8.61×
<i>FastScan p=1000</i> (高召回 0.97525)				
fastscan_pthread_dynamic_inter	1	0.97525	2402.37	1.00×
fastscan_pthread_dynamic_inter	16	0.97525	125.81	19.10×
fastscan_omp_inter	16	0.97525	139.26	14.25×
<i>IVF nprobe=4</i> (高召回 0.96225)				
ivf_pthread_pool_inter	1	0.96225	758.45	1.00×
ivf_pthread_pool_inter	16	0.96225	104.67	7.25×
ivf_omp_inter	16	0.96225	113.90	8.18×
<i>IVF-PQ local nprobe=4 p=1000</i> (高召回 0.95945)				
ivfpq_pthread_pool_inter	1	0.95945	650.09	1.00×
ivfpq_pthread_pool_inter	16	0.95945	57.61	11.28×
<i>HNSW baseline</i> / 多入口 (0.97 – 1.00)				
hnsw_baseline	1	0.96865	65.48	1.00×
hnsw_edge_omp	1	0.99915	390.91	–
hnsw_multi_entry_omp	4	1.00000	464.85	–

表 15 本地 i9-13900H 上各算法族 Recall@10 ≥ 0.95 准入下的代表性数据 (从 results/local_summary.csv 精选 22 行)。完整 319 行矩阵见 CSV 文件

B.3 AI 辅助声明

本实验在代码结构梳理、脚本编排、图表生成、LaTeX 排版和一致性检查中使用了 OpenAI Codex 等大语言模型辅助; 所有算法实现、参数选择、实验运行、性能数据采集和主要结论均由本人完成, AI 不用于生成或伪造实验数据。所有正文数字均可由 results/local_summary.csv、results/kunpeng/arm_neon_summary.csv、results/omp_schedule_sweep.txt、results/n_t_sweep.txt、results/false_sharing.txt、results/pe_affinity.txt、results/hnsw_ef_sweep.txt、results/ivf_list_histogram.csv 与 vtune_results/hotspots_report.csv 复核。

参考文献

- [1] Fabien André, Anne-Marie Kermarrec, and Nicolas Le Scouarnec. Cache locality is not enough: High-performance nearest neighbor search with product quantization fast scan. *Proceedings of the VLDB Endowment*, 9(4):288–299, 2015.
- [2] Artem Babenko and Victor Lempitsky. Efficient indexing of billion-scale datasets of deep descriptors. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2055–2063, 2016.
- [3] Hervé Jégou, Matthijs Douze, and Cordelia Schmid. Product quantization for nearest neighbor search. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33(1):117–128, 2011.

-
- [4] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with gpus. *IEEE Transactions on Big Data*, 7(3):535–547, 2021.
 - [5] Yu. A. Malkov and D. A. Yashunin. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4):824–836, 2020.